

Poids de percolation et stabilité thermodynamique sur un jeu de 186 composés

Campagne 2 : construction du jeu de données, calcul VASP+LOBSTER, et
analyse statistique

Gilles Frapper
Professeur des Universités, Chimie Théorique
IC2MP UMR 7285 CNRS, Université de Poitiers
gilles.frapper@univ-poitiers.fr

Rapport généré dans le cadre du projet `viability`

14 août 2026

Table des matières

1	Objectif et problématique	2
2	Méthodologie	2
2.1	Sélection du jeu de données	2
2.2	Classification du type de liaison	2
2.3	Calcul VASP + LOBSTER	2
2.4	Statistiques	3
3	Organigramme du workflow	3
4	Environnement	3
5	Jeu de données	3
6	Résultats	4
6.1	Corrélations (Spearman)	4
6.2	Régression logistique de référence	4
6.3	Figures	5
7	Incidents résolus	5
8	Coût de calcul	6
9	Limites et perspectives	6
10	Conclusion	6

1 Objectif et problématique

Le premier rapport (6 composés jouets) avait établi que le descripteur de percolation calculé par `percolation_path.py` diverge fortement des agrégats ICOHP classiques (somme, moyenne, min, max), sans toutefois disposer d'un échantillon assez grand pour tester statistiquement si cette différence est *utile* : le descripteur de percolation apporte-t-il une information prédictive sur la stabilité thermodynamique (`energy_above_hull`) que les agrégats classiques n'apportent pas déjà ?

Cette deuxième campagne construit un jeu de données de 186 composés (180 nouveaux + les 6 composés pilotes) réparti en trois familles :

- **exp_stable** : composés expérimentaux (référéncés ICSD) sur le hull convexe thermodynamique de Materials Project ;
- **exp_metastable** : composés expérimentaux métastables ($0 < E_{\text{hull}} \leq 100$ meV/atome) ;
- **theo_metastable** : composés théoriques (jamais observés expérimentalement) métastables ($0 < E_{\text{hull}} \leq 200$ meV/atome).

La distinction `exp_metastable` / `theo_metastable` sert de proxy pour la persistance cinétique : un composé métastable observé expérimentalement a, par définition, survécu assez longtemps pour être synthétisé et caractérisé, contrairement à un composé théorique de même métastabilité thermodynamique.

2 Méthodologie

2.1 Sélection du jeu de données

Requête Materials Project (`mp_dataset/select_campaign.py`) : systèmes chimiques unaires et binaires, non magnétiques ($|\text{laimantation totale}| \leq 0.01 \mu_B/\text{unité formulaire}$ — le champ catégoriel `magnetic_ordering` de MP est « Unknown » pour $\sim 98\%$ des entrées et aurait exclu la quasi-totalité des composés réellement non magnétiques), sans éléments f, ≤ 20 atomes/maille, 60 composés par famille avec un plafond de 2 entrées par système chimique (`chemsys`) pour garantir une diversité élémentaire plutôt qu'une accumulation de polymorphes d'un même système.

2.2 Classification du type de liaison

Le type de liaison (ionique / covalent / métallique) est calculé par la fonction `classify()` de `fetch_candidates.py` (réutilisée sans **modification**, conformément à la consigne de la campagne), à partir de `is_metal` et de la composition élémentaire. Cette classification est un axe secondaire d'analyse ici, pas l'axe d'échantillonnage principal (contrairement à la proposition initiale de plan de campagne, remplacée à la demande de l'utilisateur par le schéma stable/métastable ci-dessus).


2.3 Calcul VASP + LOBSTER

Même gabarit que la campagne pilote (calcul statique, `ISYM=-1`, `LASPH=TRUE.`, potentiels PAW-PBE recommandés par `pymatgen.io.vasp.sets.MPRelaxSet`), avec deux améliorations : `NBANDS` n'est plus une valeur fixe mais dérivée par composé du nombre d'orbitales locales de la base LOBSTER (`Lobsterin.write_INCAR`), et la détermination des fonctions de base passe par `Lobsterin.get_basis(potcar_symbols=...)` plutôt que par le parsing direct du fichier POTCAR (dont la validation interne de `pymatgen` échoue sur plusieurs POTCAR non reconnus par empreinte de hachage dans le miroir local).

2.4 Statistiques

Corrélation de Spearman (pas de raison d’attendre une relation linéaire) entre le poids de percolation (brut et normalisé par $|\text{ICOHP}_{\min}|$) et `energy_above_hull`, globalement et par type de liaison ; même chose pour les agrégats ICOHP classiques, pour comparaison directe ; régression logistique de référence (stable vs. métastable, 2–3 variables, validation croisée 5 plis) pour une AUC de référence. **Aucun SISSO, aucune régression symbolique** : prématuré avec un seul descripteur candidat et cet ordre de grandeur d’échantillon (voir §9).

3 Organigramme du workflow



4 Environnement

Identique à la campagne pilote (Yargla, VASP 6.5.0, LOBSTER 5.1.1, `.venv` Python 3.11), complété par : `mp-api`, `pandas`, `scipy`, `scikit-learn`, `matplotlib` (voir `requirements.txt`).

5 Jeu de données

Famille	n	Plage E_{hull} (eV/atome)
exp_stable	63	0.0000 (par construction)
exp_metastable	63	0.0005 – 0.0907
theo_metastable	60	0.0013 – 0.1991

Type de liaison (<code>classify()</code>)	<i>n</i>
métallique	88
covalent	23
ionique	9
non classifié	66

35% des composés (66/186) ne correspondent à aucune des trois catégories de `classify()` — principalement des pnictures/chalcogénures de métaux de transition et des composés hydrogénés, une limite réelle de l’heuristique réutilisée telle quelle, documentée mais non corrigée ici.

6 Résultats

6.1 Corrélations (Spearman)

Groupe	Métrique	<i>n</i>	ρ	<i>p</i>
tous	poids percolation (brut)	186	0.064	0.383
tous	poids percolation (normalisé)	186	0.071	0.339
métallique	poids percolation (brut)	88	0.191	0.075
métallique	poids percolation (normalisé)	88	0.222	0.038
ionique*	poids percolation (brut)	9	−0.402	0.284
covalent	poids percolation (brut)	23	0.165	0.453
tous	ICOHP somme	186	0.032	0.670
tous	ICOHP min	186	0.093	0.209
métallique	ICOHP somme	88	0.223	0.037
métallique	ICOHP min	88	0.198	0.065

* $n < 15$: à ne pas surinterpréter.

Dans le seul sous-groupe où un résultat atteint la significativité nominale (métallique, $n = 88$), le poids de percolation normalisé ($\rho = 0.222$, $p = 0.038$) et la somme des ICOHP ($\rho = 0.223$, $p = 0.037$) sont statistiquement indiscernables en force. **Le descripteur de percolation n’apporte pas d’avantage prédictif démontré par rapport aux agrégats classiques sur ce jeu de données** — une réponse plus précise que la formulation « qualitativement différent » du rapport précédent (6 composés), et plus directement exploitable.



6.2 Régression logistique de référence

Stable (hull) vs. métastable, variables : poids de percolation normalisé, ICOHP moyen, indicatrices de type de liaison ($n = 120$ après exclusion des composés non classifiés).

AUC (validation croisée, 5 plis)	0.496 ± 0.141
AUC par pli	0.556, 0.430, 0.252, 0.637, 0.607

AUC ≈ 0.5 : niveau du hasard. La dispersion importante entre plis (0.25–0.64) indique elle-même l’absence de signal stable et apprenant à cette taille d’échantillon, pas seulement un signal « faible mais réel ».

6.3 Figures



7 Incidents résolus

Conformément à la consigne (« chaque échec de job doit être loggé avec la raison probable »), 5 des 178 jobs soumis en tableau SLURM ont échoué au premier passage, tous diagnostiqués et corrigés à la source :

- **Al12W, BW, WO2, TcW, TiW** (tous contenant du tungstène) : le POTCAR `w_sv` du miroir local est dépourvu de son champ `LEXCH` (confirmé par inspection directe — présent pour toutes les autres variantes testées, y compris `W` simple), ce que VASP interprète

comme une fonctionnelle d'échange-corrélation incompatible et refuse d'exécuter. Corrigé en remplaçant la substitution `W_sv` par `W` (PBE valide, vérifié).

- **A112W** a échoué une seconde fois après cette correction, avec un SIGSEGV VASP — exactement le problème connu signalé dans la mission (`ulimit -s unlimited` avant `vasp_std`), présent dans `submit_array.sh` mais oublié dans le gabarit SLURM individuel de `prepare_vasp_lobster.py`. Corrigé ; récupéré au second essai.

Taux de succès final : **186/186**.

8 Coût de calcul

	VASP	LOBSTER
Moyenne (s)	124	397
Médiane (s)	72	145
Maximum (s)	1440	6675
Total séquentiel	6.4 h	19.1 h

Temps réel écoulé (parallélisme 8 tâches) : ~ 3.5 h, dans le budget de 6 h fixé pour la nuit.

9 Limites et perspectives

- **Taille d'échantillon** : 186 au total, mais 88/23/9 par type de liaison une fois stratifié — les corrélations « ioniques » ($n = 9$) ne sont pas interprétables.
- **Maille primitive vs. conventionnelle** (héritée du rapport pilote) : non retraitée ici. C'est probablement la cause la plus probable de la faiblesse des corrélations observées — la liaison la plus forte peut être entièrement intra-maille et ne contribuer à aucun cycle non contractile, biaisant le « maillon faible » mesuré.
- **Pas de classe « instable » au sens dynamique** : `theo_metastable` est un proxy (composé jamais synthétisé), pas un résultat de calcul de phonons.
- **Couverture de `classify()`** : 35% des composés non classifiés.
- **Pourquoi pas SISSO maintenant** : un seul descripteur candidat (le poids de percolation, sous deux variantes algébriquement liées), comparé à des agrégats eux-mêmes fonctions des mêmes valeurs ICOHP sous-jacentes — aucun espace combinatoire de recherche significatif à ce stade. Justifier SISSO demanderait : (a) plusieurs descripteurs candidats conceptuellement nouveaux, (b) un n par strate d'au moins 50–100, (c) un signal plus net qu'une AUC ≈ 0.5 .

10 Conclusion

Le jeu de données de 186 composés a été construit, calculé (VASP+LOBSTER) et analysé de bout en bout, avec deux incidents de calcul diagnostiqués et corrigés à la source. Le résultat principal est un résultat *négatif* mais chiffré et honnête : à cette taille d'échantillon, le descripteur de percolation ne montre pas de corrélation significative avec la stabilité thermodynamique, et n'apporte pas d'avantage démontré sur les agrégats ICOHP classiques. Les actions prioritaires (§9) — en particulier le retraitement en maille conventionnelle et l'extension ciblée du sous-échantillon métallique — sont susceptibles de faire évoluer ce résultat avant d'envisager un outillage de type SISSO.

Code source : <https://github.com/John-Akapulco/viability>

Données : `analysis/percolation_vs_hull.csv`

Rapport détaillé : `analysis/REPORT.md`