

Poids de percolation et stabilité thermodynamique sur un jeu de 186 composés

Campagne 2 : construction du jeu de données, calcul VASP+LOBSTER, et
analyse statistique

Gilles Frapper
Professeur des Universités, Chimie Théorique
IC2MP UMR 7285 CNRS, Université de Poitiers
gilles.frapper@univ-poitiers.fr

Rapport généré dans le cadre du projet `viability`

14 août 2026

Table des matières

1	Objectif et problématique	2
2	Méthodologie	2
2.1	Sélection du jeu de données	2
2.2	Classification du type de liaison	2
2.3	Calcul VASP + LOBSTER	2
2.4	Statistiques	3
3	Organigramme du workflow	3
4	Environnement	3
5	Jeu de données	3
6	Résultats	4
6.1	Corrélations (Spearman)	4
6.2	Régression logistique de référence	4
6.3	Figures	5
7	Incidents résolus	5
8	Coût de calcul	6
9	Limites et perspectives	6
10	Conclusion	6
A	Liste des composés	7

1 Objectif et problématique

Le premier rapport (6 composés jouets) avait établi que le descripteur de percolation calculé par `percolation_path.py` diverge fortement des agrégats ICOHP classiques (somme, moyenne, min, max), sans toutefois disposer d'un échantillon assez grand pour tester statistiquement si cette différence est *utile* : le descripteur de percolation apporte-t-il une information prédictive sur la stabilité thermodynamique (`energy_above_hull`) que les agrégats classiques n'apportent pas déjà ?

Cette deuxième campagne construit un jeu de données de 186 composés (180 nouveaux + les 6 composés pilotes) réparti en trois familles :

- **exp_stable** : composés expérimentaux (référéncés ICSD) sur le hull convexe thermodynamique de Materials Project ;
- **exp_metastable** : composés expérimentaux métastables ($0 < E_{\text{hull}} \leq 100$ meV/atome) ;
- **theo_metastable** : composés théoriques (jamais observés expérimentalement) métastables ($0 < E_{\text{hull}} \leq 200$ meV/atome).

La distinction `exp_metastable` / `theo_metastable` sert de proxy pour la persistance cinétique : un composé métastable observé expérimentalement a, par définition, survécu assez longtemps pour être synthétisé et caractérisé, contrairement à un composé théorique de même métastabilité thermodynamique.

2 Méthodologie

2.1 Sélection du jeu de données

Requête Materials Project (`mp_dataset/select_campaign.py`) : systèmes chimiques unaires et binaires, non magnétiques ($|\text{laimantation totale}| \leq 0.01 \mu_B/\text{unité formulaire}$ — le champ catégoriel `magnetic_ordering` de MP est « Unknown » pour $\sim 98\%$ des entrées et aurait exclu la quasi-totalité des composés réellement non magnétiques), sans éléments f, ≤ 20 atomes/maille, 60 composés par famille avec un plafond de 2 entrées par système chimique (`chemsys`) pour garantir une diversité élémentaire plutôt qu'une accumulation de polymorphes d'un même système.

2.2 Classification du type de liaison

Le type de liaison (ionique / covalent / métallique) est calculé par la fonction `classify()` de `fetch_candidates.py` (réutilisée sans **modification**, conformément à la consigne de la campagne), à partir de `is_metal` et de la composition élémentaire. Cette classification est un axe secondaire d'analyse ici, pas l'axe d'échantillonnage principal (contrairement à la proposition initiale de plan de campagne, remplacée à la demande de l'utilisateur par le schéma stable/métastable ci-dessus).


2.3 Calcul VASP + LOBSTER

Même gabarit que la campagne pilote (calcul statique, `ISYM=-1`, `LASPH=TRUE.`, potentiels PAW-PBE recommandés par `pymatgen.io.vasp.sets.MPRelaxSet`), avec deux améliorations : `NBANDS` n'est plus une valeur fixe mais dérivée par composé du nombre d'orbitales locales de la base LOBSTER (`Lobsterin.write_INCAR`), et la détermination des fonctions de base passe par `Lobsterin.get_basis(potcar_symbols=...)` plutôt que par le parsing direct du fichier POTCAR (dont la validation interne de `pymatgen` échoue sur plusieurs POTCAR non reconnus par empreinte de hachage dans le miroir local).

2.4 Statistiques

Corrélation de Spearman (pas de raison d’attendre une relation linéaire) entre le poids de percolation (brut et normalisé par $|\text{ICOHP}_{\min}|$) et `energy_above_hull`, globalement et par type de liaison ; même chose pour les agrégats ICOHP classiques, pour comparaison directe ; régression logistique de référence (stable vs. métastable, 2–3 variables, validation croisée 5 plis) pour une AUC de référence. **Aucun SISSO, aucune régression symbolique** : prématuré avec un seul descripteur candidat et cet ordre de grandeur d’échantillon (voir §9).

3 Organigramme du workflow



4 Environnement

Identique à la campagne pilote (Yargla, VASP 6.5.0, LOBSTER 5.1.1, `.venv` Python 3.11), complété par : `mp-api`, `pandas`, `scipy`, `scikit-learn`, `matplotlib` (voir `requirements.txt`).

5 Jeu de données

Famille	n	Plage E_{hull} (eV/atome)
exp_stable	63	0.0000 (par construction)
exp_metastable	63	0.0005 – 0.0907
theo_metastable	60	0.0013 – 0.1991

Type de liaison (<code>classify()</code>)	<i>n</i>
métallique	88
covalent	23
ionique	9
non classifié	66

35% des composés (66/186) ne correspondent à aucune des trois catégories de `classify()` — principalement des pnictures/chalcogénures de métaux de transition et des composés hydrogénés, une limite réelle de l’heuristique réutilisée telle quelle, documentée mais non corrigée ici.

6 Résultats

6.1 Corrélations (Spearman)

Groupe	Métrique	<i>n</i>	ρ	<i>p</i>
tous	poids percolation (brut)	186	0.064	0.383
tous	poids percolation (normalisé)	186	0.071	0.339
métallique	poids percolation (brut)	88	0.191	0.075
métallique	poids percolation (normalisé)	88	0.222	0.038
ionique*	poids percolation (brut)	9	−0.402	0.284
covalent	poids percolation (brut)	23	0.165	0.453
tous	ICOHP somme	186	0.032	0.670
tous	ICOHP min	186	0.093	0.209
métallique	ICOHP somme	88	0.223	0.037
métallique	ICOHP min	88	0.198	0.065

* $n < 15$: à ne pas surinterpréter.

Dans le seul sous-groupe où un résultat atteint la significativité nominale (métallique, $n = 88$), le poids de percolation normalisé ($\rho = 0.222$, $p = 0.038$) et la somme des ICOHP ($\rho = 0.223$, $p = 0.037$) sont statistiquement indiscernables en force. **Le descripteur de percolation n’apporte pas d’avantage prédictif démontré par rapport aux agrégats classiques sur ce jeu de données** — une réponse plus précise que la formulation « qualitativement différent » du rapport précédent (6 composés), et plus directement exploitable.



6.2 Régression logistique de référence

Stable (hull) vs. métastable, variables : poids de percolation normalisé, ICOHP moyen, indicatrices de type de liaison ($n = 120$ après exclusion des composés non classifiés).

AUC (validation croisée, 5 plis)	0.496 ± 0.141
AUC par pli	0.556, 0.430, 0.252, 0.637, 0.607

AUC ≈ 0.5 : niveau du hasard. La dispersion importante entre plis (0.25–0.64) indique elle-même l’absence de signal stable et apprenant à cette taille d’échantillon, pas seulement un signal « faible mais réel ».

6.3 Figures



7 Incidents résolus

Conformément à la consigne (« chaque échec de job doit être loggé avec la raison probable »), 5 des 178 jobs soumis en tableau SLURM ont échoué au premier passage, tous diagnostiqués et corrigés à la source :

- **Al12W, BW, WO2, TcW, TiW** (tous contenant du tungstène) : le POTCAR `w_sv` du miroir local est dépourvu de son champ `LEXCH` (confirmé par inspection directe — présent pour toutes les autres variantes testées, y compris `W` simple), ce que VASP interprète

comme une fonctionnelle d'échange-corrélation incompatible et refuse d'exécuter. Corrigé en remplaçant la substitution `W_sv` par `W` (PBE valide, vérifié).

- **A112W** a échoué une seconde fois après cette correction, avec un SIGSEGV VASP — exactement le problème connu signalé dans la mission (`ulimit -s unlimited` avant `vasp_std`), présent dans `submit_array.sh` mais oublié dans le gabarit SLURM individuel de `prepare_vasp_lobster.py`. Corrigé ; récupéré au second essai.

Taux de succès final : **186/186**.

8 Coût de calcul

	VASP	LOBSTER
Moyenne (s)	124	397
Médiane (s)	72	145
Maximum (s)	1440	6675
Total séquentiel	6.4 h	19.1 h

Temps réel écoulé (parallélisme 8 tâches) : ~ 3.5 h, dans le budget de 6 h fixé pour la nuit.

9 Limites et perspectives

- **Taille d'échantillon** : 186 au total, mais 88/23/9 par type de liaison une fois stratifié — les corrélations « ioniques » ($n = 9$) ne sont pas interprétables.
- **Maille primitive vs. conventionnelle** (héritée du rapport pilote) : non retraitée ici. C'est probablement la cause la plus probable de la faiblesse des corrélations observées — la liaison la plus forte peut être entièrement intra-maille et ne contribuer à aucun cycle non contractile, biaisant le « maillon faible » mesuré.
- **Pas de classe « instable » au sens dynamique** : `theo_metastable` est un proxy (composé jamais synthétisé), pas un résultat de calcul de phonons.
- **Couverture de classify()** : 35% des composés non classifiés.
- **Pourquoi pas SISSO maintenant** : un seul descripteur candidat (le poids de percolation, sous deux variantes algébriquement liées), comparé à des agrégats eux-mêmes fonctions des mêmes valeurs ICOHP sous-jacentes — aucun espace combinatoire de recherche significatif à ce stade. Justifier SISSO demanderait : (a) plusieurs descripteurs candidats conceptuellement nouveaux, (b) un n par strate d'au moins 50–100, (c) un signal plus net qu'une AUC ≈ 0.5 .

10 Conclusion

Le jeu de données de 186 composés a été construit, calculé (VASP+LOBSTER) et analysé de bout en bout, avec deux incidents de calcul diagnostiqués et corrigés à la source. Le résultat principal est un résultat *négatif* mais chiffré et honnête : à cette taille d'échantillon, le descripteur de percolation ne montre pas de corrélation significative avec la stabilité thermodynamique, et n'apporte pas d'avantage démontré sur les agrégats ICOHP classiques. Les actions prioritaires (§9) — en particulier le retraitement en maille conventionnelle et l'extension ciblée du sous-échantillon métallique — sont susceptibles de faire évoluer ce résultat avant d'envisager un outillage de type SISSO.

Code source : <https://github.com/John-Akapulco/viability>

Données : `analysis/percolation_vs_hull.csv`

Rapport détaillé : `analysis/REPORT.md`

A Liste des composés

Les 186 composés du jeu de données, classés par catégorie (famille), avec leur identifiant Materials Project, leur distance au hull thermodynamique (PBE, `energy_above_hull`) et le poids de percolation ICOHP minimal (`icohp_percolation_weight_min`, la métrique principale de ce travail). Généré automatiquement depuis `analysis/percolation_vs_hull.csv` par `report/gen_appendix.py`.

TABLE 1: Liste complète des 186 composés, classés par catégorie, avec identifiant Materials Project, distance au hull (PBE), et poids de percolation ICOHP minimal.

Formule	mp-id	Liaison	E_{hull} (eV/at)	Poids percolation (eV)
Expérimental, stable (hull) ($n = 63$)				
As ₂ S ₃	mp-1189572	covalent	0.0000	1.00e-05
AsF ₃	mp-28027	covalent	0.0000	0.00e+00
BI ₃	mp-23189	covalent	0.0000	1.00e-05
BW	mp-7832	—	0.0000	1.90e-04
BaAu ₂	mp-30363	métallique	0.0000	5.19e-02
BaCl ₂	mp-568662	ionique	0.0000	1.31e-02
BaH ₂	mp-23715	—	0.0000	2.40e-04
Be ₂ Cu	mp-2031	métallique	0.0000	1.15e-03
Be ₂ Nb ₃	mp-11272	métallique	0.0000	6.36e-03
Be ₂ V	mp-11281	métallique	0.0000	6.80e-04
CaAl ₄	mp-1749	métallique	0.0000	1.03e-02
CaSn	mp-2450	métallique	0.0000	5.23e-03
CdPd	mp-1696	métallique	0.0000	9.00e-05
CoB	mp-20857	—	0.0000	6.00e-05
Cs ₂ As ₃	mp-15557	—	0.0000	2.02e-02
FeS	mp-505531	—	0.0000	3.05e-03
Ge ₂ Os	mp-10032	métallique	0.0000	1.21e-02
HfTc ₂	mp-1095669	métallique	0.0000	1.77e-02
Hg ₄ Pt	mp-936	métallique	0.0000	3.36e-03
HgF ₂	mp-8177	—	0.0000	8.95e-03
InBr	mp-22870	covalent	0.0000	1.02e-02
KI	mp-22898	ionique	0.0000	2.26e-02
KN ₃	mp-827	—	0.0000	2.80e-04
Li ₂ Se	mp-2286	—	0.0000	1.16e-02
LiB	mp-1001835	—	0.0000	2.91e-03
Mg ₂ Ni	mp-2137	métallique	0.0000	1.60e-04
MgP ₄	mp-384	—	0.0000	0.00e+00
MnAl ₁₂	mp-1104165	métallique	0.0000	1.42e-02
MoSe ₂	mp-1634	covalent	0.0000	1.16e-03
NaS	mp-2400	—	0.0000	0.00e+00
Na	mp-10172	—	0.0000	1.97e-03
Nb ₃ Ir	mp-1458	métallique	0.0000	9.02e-03
NbGa ₃	mp-1973	métallique	0.0000	8.58e-03
PI ₂	mp-29443	covalent	0.0000	2.30e-04
PbSe	mp-2201	covalent	0.0000	1.66e-02
RbI	mp-22903	ionique	0.0000	2.00e-02
Sc ₅ Ge ₃	mp-17190	métallique	0.0000	5.30e-04
ScAg ₂	mp-1018128	métallique	0.0000	1.70e-04
ScTe	mp-10026	—	0.0000	7.12e-03
SnPt	mp-19856	métallique	0.0000	1.29e-02
SrO ₂	mp-2697	ionique	0.0000	4.40e-04

Table 1 (suite)

Formule	mp-id	Liaison	E_{hull} (eV/at)	Poids percolation (eV)
SrSi	mp-2661	métallique	0.0000	7.00e-05
Ta5Ge3	mp-17593	métallique	0.0000	3.46e-02
TaP	mp-1067587	—	0.0000	3.14e-02
TaSb2	mp-11697	métallique	0.0000	1.17e-02
Te2Pd	mp-782	—	0.0000	1.44e-02
Te2Ru	mp-267	covalent	0.0000	4.34e-03
TeO2	mp-8377	covalent	0.0000	4.00e-05
Ti3In	mp-866046	métallique	0.0000	5.01e-03
Ti3Pt	mp-2339	métallique	0.0000	1.78e-03
TiBe12	mp-1104067	métallique	0.0000	2.40e-04
TiNi	mp-1048	métallique	0.0000	3.91e-03
TiO	mp-1071163	—	0.0000	6.40e-04
TiSi2	mp-1077503	métallique	0.0000	6.18e-03
TiCl	mp-571079	—	0.0000	7.17e-03
VNi2	mp-11531	métallique	0.0000	3.88e-03
WO2	mp-1524394	—	0.0000	2.20e-04
Zr2Au	mp-2348	métallique	0.0000	3.06e-02
Zr5Pb3	mp-681992	métallique	0.0000	2.00e-05
ZrMo2	mp-2049	métallique	0.0000	1.05e-02
Si	mp-149	covalent	0.0000	3.17e-03
NaCl	mp-22862	ionique	0.0000	3.07e-02
AlNi	mp-1487	métallique	0.0000	4.19e-03
Expérimental, métastable ($n = 63$)				
CdI2	mp-567259	—	0.0005	2.38e-02
MgCl2	mp-570259	ionique	0.0006	1.90e-04
C	mp-169	covalent	0.0008	2.50e-04
ZrBr	mp-1065846	—	0.0008	7.88e-03
Li3Hg	mp-1646	métallique	0.0013	1.20e-03
Ta7Co6	mp-1104548	métallique	0.0015	3.10e-04
CaGa4	mp-2461	métallique	0.0016	1.91e-02
InCl	mp-571636	covalent	0.0016	8.50e-03
NiB	mp-14019	—	0.0018	4.10e-04
MgH2	mp-23711	—	0.0019	1.00e-05
Sn7Ir5	mp-20466	métallique	0.0024	1.00e-02
NaN3	mp-1066400	—	0.0029	7.00e-04
ClF3	mp-556767	—	0.0030	0.00e+00
SiS2	mp-1095294	covalent	0.0030	1.00e-04
Sr5Sn3	mp-17720	métallique	0.0030	1.08e-02
Te2Ir	mp-1551	—	0.0030	2.80e-03
Li13Sn5	mp-30769	métallique	0.0033	8.50e-04
H3N	mp-643432	covalent	0.0038	0.00e+00
Cs2Se	mp-1011696	—	0.0042	2.62e-02
In3Ir	mp-630976	métallique	0.0043	2.04e-03
HI	mp-697025	—	0.0044	0.00e+00
Rb2Hg7	mp-31474	métallique	0.0045	3.14e-02
PbAu2	mp-19871	métallique	0.0047	2.01e-03
BeCu	mp-2323	métallique	0.0050	4.80e-04
SiO2	mp-546794	covalent	0.0056	1.50e-04
IF7	mp-27988	—	0.0063	0.00e+00
K	mp-10157	—	0.0069	8.07e-02
Al3Os2	mp-16521	métallique	0.0074	6.23e-03
Nb2O5	mp-1595	—	0.0075	1.00e-04
LiBr	mp-23259	ionique	0.0099	9.88e-02
ZnAg	mp-1912	métallique	0.0112	9.67e-03

Table 1 (suite)

Formule	mp-id	Liaison	E_{hull} (eV/at)	Poids percolation (eV)
MgPd3	mp-7753	métallique	0.0114	2.21e-03
AsPd2	mp-1080831	—	0.0118	3.50e-04
GeSe2	mp-10074	covalent	0.0125	4.00e-05
Re3Ge7	mp-29141	métallique	0.0126	2.42e-03
Cu3Ge	mp-19724	métallique	0.0126	5.30e-04
Ti3Ge	mp-1189044	métallique	0.0130	1.40e-02
ZrGa3	mp-30685	métallique	0.0130	7.64e-03
SrAl2	mp-1638	métallique	0.0136	5.36e-03
NiS	mp-1547	—	0.0142	3.00e-04
Al12W	mp-11227	métallique	0.0152	1.37e-02
CsH	mp-632319	—	0.0161	2.66e-02
CaGa2	mp-992	métallique	0.0170	1.66e-02
NiHg4	mp-570835	métallique	0.0171	1.09e-03
SiRh	mp-2287	métallique	0.0246	1.10e-02
BaSn5	mp-571353	métallique	0.0262	4.58e-03
PS	mp-612	covalent	0.0265	8.00e-05
AsRh	mp-22079	—	0.0269	1.93e-03
Te2Au	mp-567525	—	0.0274	1.62e-02
Be3N2	mp-6977	—	0.0315	2.00e-05
Y2O3	mp-558573	—	0.0342	5.00e-05
AgO	mp-1079720	—	0.0423	4.00e-05
FeTe2	mp-1102002	—	0.0449	5.20e-04
H2O	mp-2739191	—	0.0494	0.00e+00
CdO2	mp-2310	—	0.0562	9.00e-05
Mo3Se4	mp-21021	—	0.0609	1.84e-03
PbSe	mp-22009	covalent	0.0731	1.68e-02
Be12Pd	mp-12666	métallique	0.0795	5.00e-05
Sr2As	mp-15697	—	0.0800	2.06e-03
AsRh2	mp-1102364	—	0.0806	4.63e-03
ZrRh	mp-2808	métallique	0.0839	3.50e-02
K2S	mp-559278	—	0.0873	1.07e-02
Ge4Rh	mp-1104286	métallique	0.0907	2.08e-03
Théorique, métastable ($n = 60$)				
Li3Ag	mp-976408	métallique	0.0013	1.15e-02
Y3Co	mp-1189329	métallique	0.0016	1.50e-02
TiNi	mp-1067248	métallique	0.0020	5.29e-03
TaP	mp-1187244	—	0.0033	3.59e-02
Sr3As4	mp-678007	—	0.0062	4.47e-03
Ga2Se3	mp-1224809	covalent	0.0063	1.14e-02
MnN	mp-1009130	covalent	0.0151	1.85e-03
BeCl2	mp-1190080	ionique	0.0187	2.37e-03
MgSn	mp-1094801	métallique	0.0212	4.26e-03
TiW	mp-1216621	métallique	0.0225	2.25e-03
SrTi3	mp-1206636	métallique	0.0294	3.29e-03
IrCl3	mp-729507	—	0.0301	2.72e-03
Ta4C3	mp-1218000	—	0.0335	1.44e-03
Sc2O3	mp-755313	—	0.0364	5.10e-04
SnBr2	mp-978985	covalent	0.0405	3.40e-04
Sn7Pd5	mp-1219006	métallique	0.0414	2.30e-03
Tl4Sn	mp-1216560	métallique	0.0459	1.00e+00
LiTi3	mp-1185253	métallique	0.0467	3.35e-03
PtCl2	mp-1219748	—	0.0490	5.04e-03
HCl	mp-684609	—	0.0536	2.50e-04
MgSn	mp-1094669	métallique	0.0560	2.60e-04

Table 1 (suite)

Formule	mp-id	Liaison	E_{hull} (eV/at)	Poids percolation (eV)
K5As4	mp-684799	–	0.0564	8.80e-03
KSn3	mp-1185151	métallique	0.0573	2.65e-02
NbS2	mp-774873	–	0.0576	1.20e-04
YAg3	mp-1187811	métallique	0.0594	1.12e-03
B3Ir2	mp-1228647	–	0.0609	2.80e-04
TiMo2	mp-1216675	métallique	0.0613	3.77e-02
Cr2C	mp-1226378	–	0.0625	2.08e-03
ZrO2	mp-775909	–	0.0627	1.20e-04
Zn	mp-2647117	–	0.0717	1.04e-02
IN2	mp-1097011	–	0.0730	4.70e-04
CoSe2	mp-1390196	–	0.0734	8.40e-04
GeS	mp-12910	covalent	0.0762	2.26e-03
ZrTi	mp-1215236	métallique	0.0883	3.15e-02
VCo3	mp-1095057	métallique	0.0942	2.93e-03
Tl3Ga	mp-1187539	métallique	0.0972	5.00e-05
CaGe2	mp-643542	métallique	0.0979	1.30e-02
NbRh2	mp-1220414	métallique	0.1043	1.76e-02
TcW	mp-1217337	métallique	0.1056	4.10e-03
MgF2	mp-560236	ionique	0.1076	2.00e-05
VN	mp-1017532	–	0.1080	4.00e-05
Na2Cl	mp-990084	–	0.1105	3.76e-02
ZnPb3	mp-1187949	métallique	0.1107	4.51e-03
Sr3Sn	mp-1187136	métallique	0.1111	7.94e-03
TaRe	mp-1217894	métallique	0.1113	6.98e-02
Al4Si	mp-1228120	métallique	0.1149	8.54e-02
B6Pb	mp-1096825	covalent	0.1151	2.35e-03
ScTc3	mp-867262	métallique	0.1154	3.31e-02
CrMo	mp-1226200	métallique	0.1163	4.23e-02
BPd5	mp-1228665	–	0.1325	2.42e-02
Zr3Be	mp-1188016	métallique	0.1430	1.05e-03
Na3Cl	mp-1064484	–	0.1456	2.55e-03
SiAu3	mp-1186998	métallique	0.1643	5.68e-03
InSe2	mp-1232036	–	0.1733	1.64e-03
TiSi2	mp-570991	métallique	0.1796	1.35e-02
BeAu3	mp-983539	métallique	0.1818	2.41e-02
Zr3Ge	mp-1188039	métallique	0.1851	6.59e-03
AlSb	mp-1023918	métallique	0.1878	3.60e-04
Mg15B	mp-1023515	–	0.1943	2.80e-04
HfMo	mp-1224314	métallique	0.1991	2.00e-02